Module : Machine Learning
Filière : CCN-2

TD N°1

Exercice 1 : QCM

1 On a un tableau X sans étiquette y et on veut segmenter une base clients pour explorer des profils. Quel paradigme convient ? ☐ **A**. Supervisé. ☐ **B**. Non supervisé. ☐ **C**. Renforcement. ☐ **D**. Semi-supervisé.	**2 Dans un pipeline d'apprentissage automatique, à quel moment isole-t-on le jeu de test pour éviter toute fuite de données et obtenir une évaluation honnête ?** ☐ **A**. Lors de la définition de X et y. ☐ **B**. Après le tuning des hyperparamètres. ☐ **C**. Au moment du split (train/test), avant la mise à échelle. ☐ **D** Juste avant l'évaluation finale.
3 On entraîne un classifieur malware vs bénin. On veut conserver la prévalence de "malware" dans train/val/test. Quel partitionnement choisit-on ? ☐ **A**. Aléatoire simple. ☐ **B**. Stratifié. ☐ **C**. Temporel. ☐ **D** . K-fold non stratifié.	**4 On standardise des features réseau numériques avant entraînement d'un IDS. Comment procède-t-on pour éviter la fuite?** ☐ **A**. On ajuste le scaler sur tout le dataset avant le split (plus stable). ☐ **B**. On ajuste le scaler sur test. ☐ **C**. On ajuste le scaler sur train uniquement, puis on applique à val/test.
5 On exécute : **df.isna().sum().sort_values(ascending=False)** **Qu'obtient-on ?** ☐ **A**. Le nombre de valeurs manquantes par colonne, trié décroissant. ☐ **B**. Les classes de la cible. ☐ **C**. Le nombre de doublons par colonne. ☐ **D** Les statistiques descriptives des colonnes.	**6 On exécute :** **df.nunique().sort_values(ascending=False)** **Qu'obtient-on ?** ☐ **A**. Détecter les NaN. ☐ **B**. La variance. ☐ **C**. La cardinalité pour repérer les colonnes constantes, catégorielles et continues ☐ **D** Détecter les valeurs extrêmes.
7 On observe des chaînes "?", "-", "inf", "INF" dans le CSV. Quel code convertit ces marqueurs en vrais NaN avant imputation ? ☐ **A**. df.fillna({"?":0,"-":0,"inf":0,"INF":0}). ☐ **B**. df.replace(np.nan, {"?":None,"-":None}). ☐ **C**. df = df.replace({"-": np.nan, "?": np.nan, "inf": np.nan, "INF": np.nan}). ☐ **D** df.dropna().	**8 Que renvoient ces deux lignes ?** **dup_count = int(df.duplicated().sum())** **df["attack_detected"].value_counts()** ☐ **A**. Le nombre de lignes identiques, puis les effectifs de chaque classe de la cible. ☐ **B**. Le nombre de colonnes dupliquées. ☐ **C**. Les NaN par colonne.

9 Pourquoi ajoute-t-on une étape "vérification de l'intégrité métier" ? ☐ **A**. Pour augmenter la taille du dataset. ☐ **B**. Pour vérifier les types techniques après parsing. ☐ **C**. Pour détecter des valeurs incohérentes avec la réalité métier et les corriger ou marquer comme anomalies.	**10 Quel appel produit un tableau avec count, mean, std, min, 25%, 50%, 75%, max pour les colonnes numériques ?** ☐ **A**. df.info(). ☐ **B**. df.describe(). ☐ **C**. df.head(). ☐ **D**. df.value_counts().
11 On écrit : X = df.iloc[:, :-1] y = df.iloc[:, -1] Dans quel cas cet extrait est-il correct sans risque ? ☐ **A**. Quand la cible est en dernière position. ☐ **B**. Quand la cible est la première colonne. ☐ **C**. Quand les colonnes peuvent être réordonnées plus tard.	**12 On entraîne une régression linéaire avec intercept. Que change la standardisation?** ☐ **A**. $\hat{Y}$ changent mais R^2 reste identique. ☐ **B**. $\hat{Y}$ et R^2 restent (pratiquement) identiques ; seuls les coefficients changent d'échelle. ☐ **C**. R^2 change car la variance de y change après scaling de X.
13 regressor = LinearRegression() On veut ENTRAÎNER le modèle sur l'ensemble d'apprentissage. Quelle est la méthode correcte à appeler ? ☐ **A**. regressor.predict(X_train, y_train). ☐ **B**. regressor.fit(X_train, y_train). ☐ **C**. regressor.fit(X_test, y_test). ☐ **D**. regressor.fit_transform(X_train, y_train)	**14 R^2 ajusté : Quel énoncé est correct à propos de R^2 ajusté ?** ☐ **A**. Augmente mécaniquement avec chaque variable ajoutée. ☐ **B**. N'augmente que si la variable améliore réellement le modèle ; utile pour comparer des tailles de modèles différentes. ☐ **C**. Équivaut à R^2.
15 Le VIF de Xj reflète : ☐ **A**. L'influence de Xj sur Y uniquement. ☐ **B**. Le biais d'approximation. ☐ **C**. L'incertitude de βj à cause de la corrélation entre Xj et les autres X. ☐ **D**. La corrélation entre Y et les résidus du modèle.	**16 On encode en One Hot une variable à 3 modalités avec intercept. Que doit-on faire ?** ☐ **A**. Garder 3 dummies + intercept. ☐ **B**. Supprimer l'intercept et garder 3 dummies. ☐ **C**. Garder K−1 dummies (2 colonnes), la catégorie omise devient la base. ☐ **D**. Opter pour un encodage en entier.
17 On prédit un prix en kDH. Sur le jeu de test on obtient: MAE = 12, RMSE = 20. Quelle affirmation est fausse ? ☐ **A**. MAE = 12 kDH signifie qu'en moyenne absolue on se trompe d'environ 12 kDH. ☐ **B**. RMSE = 20 kDH signifie que l'erreur quadratique moyenne est ~20 kDH, plus sensible aux grosses erreurs que le MAE. ☐ **C**. MAE et RMSE ne doivent pas être comparés à l'unité de Y.	**18 Dans PolynomialFeatures(degree=4, include_bias=False), pourquoi met-on include_bias=False ?** ☐ **A**. Pour éviter d'ajouter la colonne de 1 car LinearRegression apprend déjà un intercept. ☐ **B**. Pour empêcher la création de termes croisés. ☐ **C**. Pour normaliser automatiquement les features polynomiales générées.

19 Les scalers de scikit-learn attendent un tableau 2D (n_samples, n_features). Si y est un vecteur 1D (n,), comment le mettre à l'échelle correctement (puis revenir en 1D) ? ☐ **A**. y_scaled = sc_y.fit_transform(y). ☐ **B**. y_scaled = sc_y.fit_transform(y).ravel() ☐ **C**. y_scaled = sc_y.fit_transform(y).reshape(-1, 1) ☐ **D**. y_scaled = sc_y.fit_transform(y.reshape(-1, 1)).ravel()	**20 Dans SVR(kernel='rbf'), que signifie RBF ?** ☐ **A**. Un noyau gaussien adapté aux relations linéaires en X. ☐ **B**. Un noyau polynomial dont le degré est contrôlé par degree. ☐ **C**. Un noyau gaussien qui mesure une similarité locale (dépendante de γ), adapté aux relations non linéaires. ☐ **D**. Un séparateur strictement linéaire.
21 Dans : **sc_y.inverse_transform(regressor.predict(sc_X.transform([[9.5]])).reshape(-1, 1)) que fait inverse_transform ?** ☐ **A**. Elle "dé-standardise" X en appliquant le scaler sc_X à l'envers. ☐ **B**. Elle remet la prédiction dans l'unité d'origine de y (elle annule la standardisation selon mean_/scale_ appris par sc_y) ☐ **C**. Elle convertit le vecteur en matrice 2D.	**22 En régression, quel énoncé décrit correctement le principe d'un arbre CART ?** ☐ **A**. À chaque nœud, on cherche le seuil qui minimise le MAE ; en feuille, on prédit la moyenne de y. ☐ **B**. À chaque nœud, on cherche le seuil qui maximise le gain d'entropie ☐ **C**. À chaque nœud, on cherche le seuil sur une variable qui minimise le MSE ; en feuille, on prédit la moyenne des valeurs de y.
23 En Dataset de 28 points. On entraîne un CART (régression) avec max_depth=None, min_samples_split=2, min_samples_leaf=1, min_impurity_decrease=0. Que se passe-t-il au pire ? ☐ **A**. Jusqu'à 27 coupures, feuilles d'un point, MSE train = 0 (sur-ajustement). ☐ **B**. Jusqu'à 27 coupures, feuilles de 2 points minimum, MSE train peut rester non nulle. ☐ **C**. Jusqu'à 26 coupures.	**24 En Random Forest avec bootstrap=True, que signifie "tirage avec remise" pour chaque arbre ?** ☐ **A**. Toutes les lignes du dataset sont utilisées une seule fois par arbre, sans répétition. ☐ **B**. On tire aléatoirement des lignes du dataset avec remise, certaines sont répétées et d'autres ne sont jamais vues par l'arbre (OOB). ☐ **C**. Le tirage avec remise s'applique uniquement aux colonnes et non aux lignes.
25 En classification binaire, que "prévoit" le modèle ? ☐ **A**. ne étiquette 0/1 directement (méthode : predict → applique un seuil interne ~0.5). ☐ **B**. Une probabilité $p = \Pr(y = 1 \mid x)$, puis on décide via un seuil τ(méthodes : predict_proba → [:,1] ☐ **C**. Un vecteur de probabilités.	**26 Quelle métrique devient trompeuse si la classe positive est très rare ?** ☐ **A**. L'accuracy, car un modèle peut prédire toujours la classe majoritaire et sembler performant. ☐ **B**. Le recall, car il ignore les vrais négatifs. ☐ **C**. La précision, car elle ne tient pas compte des faux négatifs.

27 Quand on diminue le seuil de décision τ (de 0.9 vers 0.1), quel est l'effet typique ?	28 À propos des courbes ROC et PR, laquelle de ces propositions est fausse ?
☐ **A**. Le rappel (Recall/TPR) diminue, la précision augmente, et le FPR diminue. ☐ **B**. Rappel et précision augmentent toujours ensemble. ☐ **C**. Le rappel augmente, le FPR augmente, et la précision a tendance à baisser (plus de FP). ☐ **D**. Seule la précision change ; le rappel reste constant.	☐ **A**. La ROC trace TPR (rappel) vs FPR pour tous les seuils. ☐ **B**. La PR trace Précision vs Rappel et est plus informative quand la classe positive est rare. ☐ **C**. AUC-ROC ≈ probabilité qu'un positif ait un score > à un négatif. ☐ **D**. En fort déséquilibre, on préfère ROC à PR.

29

```
tau = 0.35
proba_pos = model.predict_proba(X_test_scaled)[:, 1]
y_pred_tau = (proba_pos >= tau).astype(int)
```

Que fait exactement ce code ?

☐ **A**. Il applique un seuil 0,35 aux probabilités de la classe 1 puis renvoie des étiquettes 0/1 dans y_pred_tau.

☐ **B**. Il applique un seuil 0,35 aux probabilités de la classe 0 et renvoie des étiquettes 0/1 dans y_pred_tau.

☐ **C**. Il arrondit directement les probabilités de la classe 1 (>0.5 → 1 sinon 0)

Exercice 2: On souhaite prédire l'énergie d'un centre de données à partir de ces caractéristiques:

- CPU_Util : taux d'utilisation processeur de l'infrastructure (moyenne sur l'intervalle).
- Net_Mbps : débit réseau moyen mesuré
- Temp_C : température d'air à l'entrée des racks.
- DayType (Workday/Weekend) : type de jour (la charge est plus faible le week-end).
- → cible : Energy_kWh: énergie consommée pendant un intervalle de 15 minutes.

1) Complétez le code suivant par ce qui est demandé en commentaires :

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_absolute_error, root_mean_squared_error, r2_score
```

```
df = pd.read_csv("dc_energy.csv")
df.head()
```

	CPU_Util	Net_Mbps	Temp_C	DayType	Energy_kWh
0	27.57	15.5	21.98	Workday	6.236
1	90.21	1.0	25.55	Workday	8.831
2	22.04	99.7	25.47	Workday	4.693
3	21.14	84.1	23.46	Weekend	5.036
4	36.49	81.7	24.18	Workday	5.822

```
# Séparer la cible y et les features X
```

```
# 2) Encodage one-hot de DayType SANS drop_first
#    -> crée DEUX colonnes : DayType_Workday et DayType_Weekend (0/1)
```

```
# Afficher les dimensions de X et y :
```

```
# Vérifier l'absence de valeurs manquantes (NA) dans X et Y
```

```
# SPLIT TRAIN/TEST
# - 80%/20%, random_state=0
# - Sorties attendues : X_train, X_test, y_train, y_test
```

```
# STANDARDISATION
# - StandardScaler() : fit sur X_train, transform sur X_train et X_test
# - Sorties : X_train_s, X_test_s
```

```
# MODÈLE RandomForest avec 300 arbres
# profondeur de 8, 4 échantillons minimum pour un split
# au moins 3 échantillons dans une feuille et random state =0
# toutes les variables testées
```

```
# Entrainement du modèle
```

```
# Prédictions: Prédire sur l'ensemble d'entraînement et sur l'ensemble de test
# Stocker dans y_pred_train la prédiction du modèle sur X_train_s
# Stocker dans y_pred_test  la prédiction du modèle sur X_test_s
```

```
# Calculer les métriques RMSE_train, RMSE_test, MAE_test, r²_train et r²_test
# Puis, afficher ces métriques avec 3 décimaux après virgule
```

2) Les résultats des métriques obtenus sont :

```
RMSE (train) = 0.572 kWh/15min
RMSE (test)  = 1.067 kWh/15min
MAE  (test)  = 0.891 kWh/15min
R²   (train) = 0.848
R²   (test)  = 0.454
```

-Que signifient MAE et RMSE en unités métier ? Comment lire leurs valeurs ?

-Le modèle généralise-t-il correctement ?

-Comment interpréter R^2_test ≈ 0.454 ?

-Interprétez le graphique Résidus vs Prédictions (test).

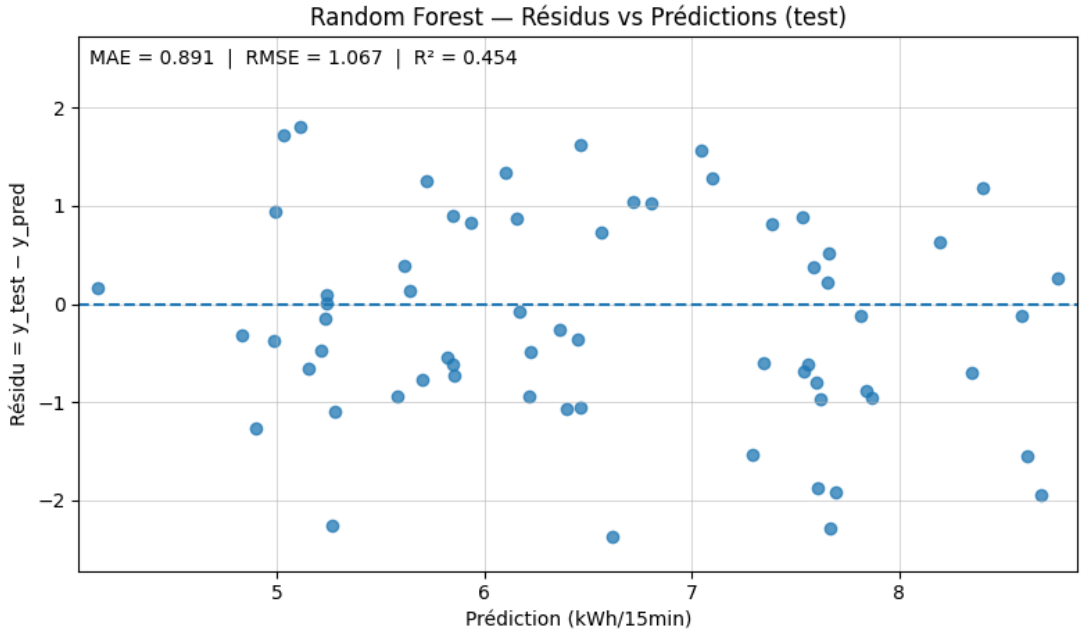

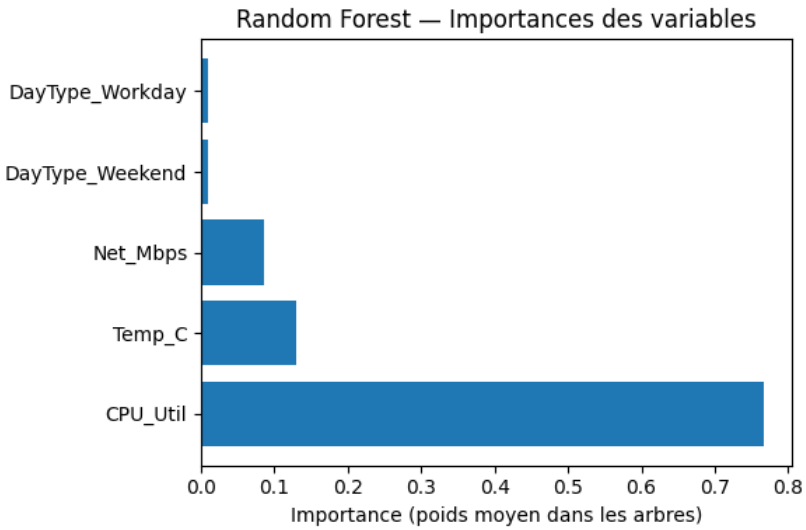

<u>Note</u> : Poids moyen dans les arbres = l'importance des variables calculée par la forêt comme la réduction moyenne d'impureté que chaque feature apporte, moyennée sur tous les arbres et normalisée

-En se référant au graphe ci-dessus et aux résultats précédents, quelles sont vos suggestions pour améliorer les résultats du modèle ?